Previsão Temporal de Suspensão Experimental e Estimativa de um Indicador de Conforto com LSTM

Pedro Druck Montalvão Reis
Disciplina: Inteligência Artificial II

***Abstract*—Aplica-se uma LSTM à previsão de cinco segundos de suspensão experimental, condicionada à pista futura conhecida, nas classes A–E de um benchmark público. Além de trajetórias, estima-se um indicador de RMS ponderado da aceleração. Com 30 épocas, a classificação alcançou 94,4%, ante 100% de uma regressão com características construídas. Uma auditoria independente reproduziu os números, mas identificou que persistir o RMS passado também alcança 100%. Dentro de cada realização, A–E são formas de onda proporcionais, e os rótulos permanecem praticamente separados por classe. O limite de 30 épocas não demonstrava estabilização; um diagnóstico com até 120 épocas elevou a LSTM conjunta a 100%, reduzindo seu erro de RMS. A auditoria não sustenta inferioridade geral da arquitetura nem necessidade de deep learning para esse indicador. Os alvos são sensíveis ao filtro e não representam conforto validado em passageiros.**

***Index Terms*—suspensão, LSTM, séries temporais, previsão condicionada, conforto vibracional.**

I. Introdução

Antecipar a resposta da suspensão à irregularidade da pista pode apoiar a análise de condições de rodagem. O problema envolve memória dinâmica: um mesmo deslocamento imposto pode gerar respostas distintas conforme o estado anterior. Neste projeto, aplica-se uma LSTM como técnica conhecida de aprendizado sequencial, sem reivindicar uma arquitetura inédita. O trabalho se enquadra no tema II da disciplina, aplicação de algoritmos à solução de um problema.

A pergunta investigada é se uma previsão condicionada à pista futura pode antecipar um indicador de desconforto em uma realização diferente da usada no ajuste. O conhecimento da excitação futura é uma hipótese explícita: o experimento prevê a resposta a uma pista especificada, não uma pista aleatória desconhecida. As contribuições práticas são o treinamento selecionável por classe de pista, a separação dos trechos repetidos e a avaliação conjunta de trajetórias e decisão agregada.

II. Dados e Formulação

O benchmark de Foo e Tan reúne perfis multissenoidais associados às classes ISO 8608 A–E, aplicados à bancada Quanser, com deslocamentos medidos da carroceria e do pneu [1], [2]. A representação aproximada tem duas coordenadas livres: carroceria z_s e roda z_u, sob elevação prescrita z_r. A deformação relativa da suspensão é $z_s - z_u$.

Cada entrada contém 100.000 amostras a 1.000 Hz, repetidas quatro vezes na aquisição das saídas. Descartou-se o primeiro período de 100 s. O teste usa as realizações com supressão de harmônicos, também geradas com outras fases; portanto, há mudança simultânea da realização e da estrutura harmônica. Não há relatos de passageiros nem representação completa de um veículo [2].

Deformação, frequência de excitação, frequência dominante e frequência natural são grandezas distintas. A condição de frequência dominante até 2 Hz é uma meta adicional do projeto, não uma garantia de conforto. O indicador principal é uma aproximação espectral do RMS da aceleração vertical ponderada:

$$a_w = \left[\sum_{f_k \in [0.5,80]} G_{aa}(f_k) |W_k(f_k)|^2 \Delta f \right]^{1/2}, \qquad (1)$$

com periodograma Hann e ponderação vertical W_k. Os parâmetros das funções de transferência foram conferidos no apêndice A.4 de referência técnica [3]. Testes com ganhos tabulados em 3,15, 12,5 e 50 Hz e uma senoide reproduziram as referências com tolerância de 2%.

Define-se desconforto estimado quando $a_w \geq 0{,}315$ m/s^2, simplificando uma referência indicativa [4]. Essa regra não é limite universal ou certificação ISO. A frequência dominante da carroceria é obtida separadamente na banda 0,5–15 Hz. A resolução básica em cinco segundos é aproximadamente 0,2 Hz.

III. Metodologia

A. Processamento e separação

Os offsets foram estimados nos cinco segundos iniciais de calibração de cada aquisição, anteriores à avaliação. A aceleração é a segunda diferença regressiva do deslocamento, suavizada por filtro causal de quarta ordem a 80 Hz. Um filtro antialias causal comum de oitava ordem a 100 Hz antecede a redução para 250 Hz. Atrasos e atenuações tornam o alvo uma aceleração processada, não uma medição independente.

Checksum, dimensões, valores finitos e pareamento foram conferidos. A análise adicional padronizou os cortes de 40, 60 e 80 Hz, mantendo idênticos centralização, antialias, amostragem e janelas. Testou-se também uma senoide de amplitude conhecida com ruído sintético em níveis definidos. Esses diagnósticos não identificam o ruído real da bancada. O alvo de 80 Hz foi mantido, sem selecionar a banda pela acurácia.

Cada exemplo tem cinco segundos de histórico e cinco futuros. No treino, usam-se períodos 2 e 3 sem supressão, com histórico e alvo integralmente entre as fases locais 5–60 s. A validação usa fases 70–100 s dos períodos úteis. Todas as

TABLE I
JANELAS POR MODALIDADE E CONJUNTO.

Treino	Treinamento	Validação	Teste
Somente C	92	15	54
A–E	460	75	270

repetições da mesma fase ficam no mesmo grupo temporal. O teste usa apenas as realizações com supressão, períodos 2–4. Normalizadores são ajustados exclusivamente no treino.

O avanço é de um segundo no treino e cinco na validação e teste. Os testes contêm três repetições da realização por classe, não três novos perfis independentes. A e B apresentam apenas o rótulo de conforto; C–E, apenas desconforto no recorte principal. Essa associação limita a interpretação da classificação.

B. Rede, treinamento e referências

Um encoder LSTM recebe o histórico de z_r, z_s, z_u. Um decoder LSTM recebe a pista futura e o estado do encoder, sem saídas futuras reais. Ambos têm uma camada e 64 unidades. Uma projeção linear produz trajetórias de z_s, z_u e aceleração; outra cabeça linear, aplicada à média temporal dos estados do decoder, estima $\log a_w$. Há 35.076 parâmetros.

A cabeça agregada foi adicionada após um piloto de desenvolvimento: a aceleração prevista pontualmente gerou RMS médio de 0,00162 m/s^2, contra 0,5063 m/s^2 na validação. A alteração antecedeu a abertura do teste. A perda é

$$\mathcal{L} = \mathrm{MSE}(\hat{\boldsymbol{y}}_{norm}, \boldsymbol{y}_{norm}) + 0.2\,\mathrm{MSE}(\widehat{\log a_w}, \log a_w). \quad (2)$$

Utilizou-se Adam, taxa 10^{-3}, lote 16, limite da norma do gradiente igual a 1, até 30 épocas e paciência de cinco. Restaurou-se o checkpoint de menor perda de validação nas sementes 42, 43 e 44. O global tem cinco vezes mais janelas que o especializado, mantendo a arquitetura. As execuções usaram T4 via Colab CLI, PyTorch 2.11.0, NumPy 2.4.6 e SciPy 1.16.3. Os seis checkpoints foram recarregados e seus hashes congelados antes do teste.

As referências são persistência da última saída e ARX multivariado com 20 atrasos dos três sinais físicos, entrada de pista atual e regularização ridge 0,1. A previsão ARX é recursiva, sem realimentação futura real. Seus indicadores vêm das trajetórias; a LSTM é avaliada por trajetória e cabeça agregada.

Em uma segunda análise exploratória, acrescentaram-se três referências diretas para $\log a_w$: média constante do treino; regressão com log-desvio padrão da pista futura; e ridge com oito características logarítmicas. Estas incluem desvios padrão da pista futura, da carroceria, pneu e pista históricos, RMS das primeiras e segundas diferenças da pista futura e desvios padrão do curso relativo e da diferença pneu–pista no histórico. A classe ISO e as respostas futuras não são entradas. A padronização usa apenas o treino. A regularização é escolhida em $\{0{,}001; 0{,}01; 0{,}1; 1; 10; 100\}$ pela perda de validação em log-RMS. Para A–E, selecionou-se 0,001 nas duas regressões.

TABLE II
TRAJETÓRIA: RMSE DA CARROCERIA EM MM.

Treino	Persistência	ARX	LSTM
C	1,006	0,185	0,254
A–E	2,214	0,488	0,669

TABLE III
INDICADOR DIRETO GLOBAL: ANÁLISE EXPLORATÓRIA ADICIONAL.

Método	MAE[a]	Acc. (%)	Macro-F1
Constante	0,453	60,0	0,375
Amplitude da pista	0,134	96,7	0,966
Ridge, 8 características	0,062	100,0	1,000
LSTM, cabeça agregada	0,121	94,4	0,941

[a] Erro de a_w em m/s^2. LSTM: média das três sementes. Os resultados são concordância com rótulos processados.

Essas referências são comparadas à cabeça agregada; ARX e LSTM são comparados separadamente como preditores de trajetória. O teste original já havia sido consultado antes dessa ampliação, que não constitui um novo teste cego. Não houve retreino da LSTM orientado por seus resultados.

Avaliam-se erros de deslocamento, aceleração, indicador, frequência, pico e curso relativo, incluindo RMSE acumulado até 0,1, 0,5, 1 e 5 s. Para a classificação, usam-se acurácia, macro-F1, acurácia balanceada e recall de desconforto. Métricas de discriminação são omitidas quando só há uma classe verdadeira. Não se calculam intervalos de confiança que suponham independência das janelas correlacionadas.

IV. RESULTADOS E DISCUSSÃO

No global, a LSTM obteve acurácia 0,9444, macro-F1 0,9406 e acurácia balanceada 0,9306 nas três sementes (Tabela III). A matriz de confusão foi idêntica: 93 confortos corretos, 15 falsos alertas de desconforto, 162 desconfortos detectados e nenhum falso conforto. Predizer sempre desconforto, a classe majoritária do treino global, atingiria 60% de acurácia nesse teste.

A Tabela III muda a interpretação da classificação: a amplitude da pista, isoladamente, alcançou 96,7%, e a ridge de oito características, 100%. O MAE desta última foi 0,062 m/s^2, inferior a 0,121 da LSTM. Como as classes de pista praticamente separam os rótulos, a rede pode reconhecer intensidade sem aprender transições de conforto dentro de cada classe. Na configuração de 30 épocas, o desempenho agregado não estabelece vantagem da LSTM frente às referências diretas. Os 100% também não validam conforto humano ou generalização para novas configurações.

O MAE do indicador global foi $0{,}121 \pm 0{,}009$ m/s^2 e o RMSE de carroceria $0{,}669 \pm 0{,}034$ mm, com desvio entre sementes. O ARX teve melhor trajetória, com RMSE de 0,488 mm. Os resultados não sustentam superioridade geral da LSTM: há diferenças entre previsão temporal e decisão agregada.

A Fig. 1 ilustra tendências acompanhadas e variações não reproduzidas. Calcular conforto diretamente da aceleração

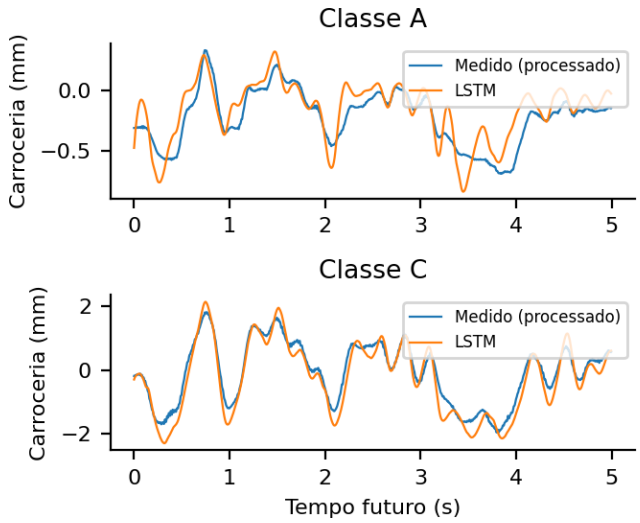


Fig. 1. Primeira janela válida do teste em A e C, modelo global, semente 42. A seleção segue a ordem temporal, não o menor erro. Os deslocamentos medidos são processados.

temporal da LSTM global produziu acurácia entre 45,6% e 57,8%, inferior à cabeça agregada. Logo, boa classificação não valida toda a trajetória de aceleração nem a consistência física entre as saídas.

Em C, sempre indicar desconforto permite 100% de acerto, sem demonstrar discriminação binária. A LSTM especializada obteve RMSE de 0,254 mm, ante 0,289 mm do global nesse mesmo teste C. A diversidade não melhorou automaticamente essa classe, e a diferença na quantidade de treino impede isolar seu efeito.

A separação dos rótulos por classe sugere um fator de confusão: reconhecer amplitudes associadas à rugosidade pode explicar parte do desempenho, sem aprender transições de conforto dentro de cada classe. A ausência de falsos confortos nesse teste correlacionado não deve ser generalizada. Na demonstração salva, 0,6 Hz de frequência prevista coexistiu com RMS aprendido próximo de 0,750 m/s^2, ilustrando que até 2 Hz não substitui um indicador de intensidade.

Na análise padronizada de C no teste, os cortes de 40, 60 e 80 Hz produziram intervalos de a_w de 0,245–0,333, 0,394–0,510 e 0,428–0,549 m/s^2, respectivamente. Reduzir de 80 para 40 Hz alterou 53 dos 54 rótulos. No corte principal, 93,2% da energia ponderada de C estava entre 20 e 80 Hz. Isso não demonstra que tal energia seja ruído, mas impede assumir a validade física dos rótulos sem uma medição independente.

As curvas de treino/validação, dispersões do indicador e erros por classe e horizonte foram exportados. A análise por passagem e após média das fases repetidas evita interpretar as 270 janelas globais como 270 ensaios independentes: há 90 fases distintas, de uma realização por classe. Não são apresentadas significâncias estatísticas baseadas em independência inexistente.

As principais limitações são a sensibilidade da aceleração derivada ao filtro e ao ruído, a quantidade limitada de realizações, a correlação entre repetições, a hipótese de pista futura conhecida e a ausência de assento e passageiros. Não se variaram parâmetros mecânicos da suspensão. A classificação é concordância com um alvo numérico de bancada.

TABLE IV
DIAGNÓSTICO GLOBAL: MÉDIAS DE TRÊS SEMENTES NA LSTM.

Método	Acc. (%)	MAE RMS^a	RMSE^b
LSTM conjunta, 30 épocas	94,4	0,121	0,669
LSTM conjunta, até 120	100,0	0,082	0,484
LSTM só RMS, até 120	99,3	0,085	–
Ridge, 8 características	100,0	0,062	–
RMS passado, persistência	100,0	0,045	–

^{a}m/s^2. ^{b}Carroceria em mm. A variante só RMS não treina trajetórias. ARX original: 0,488 mm.

A. Auditoria independente e orçamento de treinamento

O RMS foi recalculado com FFT explícita e funções de transferência polinomiais, e a regressão por mínimos quadrados ampliados/SVD. As diferenças máximas foram $8{,}8 \times 10^{-9}$ e $1{,}1 \times 10^{-9}$ m/s^2, respectivamente, reproduzindo os 100%. Não se encontrou sobreposição das fases completas de treino/validação ou normalização pelo teste nas verificações realizadas. Esses controles não provam ausência de toda dependência entre observações.

Dentro de cada realização, as entradas A–E são proporcionais, com resíduo relativo da ordem de 10^{-16}: há cinco amplitudes, não cinco formas independentes. Persistir o RMS dos cinco segundos anteriores também atingiu 100%, com MAE 0,045 m/s^2. Nas 100 permutações agrupadas de alvos de treino, a mediana de acerto caiu para 60%; não se interpreta esse controle como p-valor, pois janelas vizinhas se sobrepõem. O acerto perfeito não persiste em qualquer fronteira: na Ridge, os limiares diagnósticos de 0,5 e 1,0 resultaram em 92,2% e 89,6%, sem seleção de um novo limiar.

Cinco das seis melhores validações originais ocorreram na época final, 30. Assim, fixaram-se dois diagnósticos adicionais: mesma LSTM, sementes 42–44, até 120 épocas e paciência 15; um mantém a perda conjunta, outro otimiza apenas log-RMS. A seleção utiliza somente validação. A atualização do otimizador foi verificada no T4, inclusive após a troca CPU/GPU dos checkpoints; não se encontrou interrupção da atualização nessa versão. Como o teste já era conhecido, os diagnósticos são exploratórios.

A LSTM conjunta longa atingiu 100% nas três sementes, com MAE médio de RMS de 0,082 m/s^2 e RMSE de deslocamento de 0,484 mm, próximo de 0,488 do ARX. A diferença varia entre sementes e não estabelece superioridade estatística. A regressão e a persistência do RMS continuam com menor erro agregado. A comparação anterior subestimava a rede, mas o teste continua pouco exigente para classificação: intensidade estável e rótulos separados por classe. Além disso, a Ridge recebe estatísticas prontas e resolve apenas um alvo, enquanto a LSTM original aprende representações temporais e vários alvos.

A sequência completa foi reexecutada em outro runtime T4, incluindo obtenção dos dados, processamento, ajuste das referências, seis treinamentos, congelamento e avaliação. Vinte e três testes passaram nessa reprodução; a auditoria adicional passou em 26 testes e preservou seus seis novos checkpoints após verificar o download. A conferência das métricas de RMSE da carroceria, MAE do indicador e acurácia, por execução e classe, não encontrou diferenças em relação aos registros originais. Pesos, logs, hashes e uma cópia do código executado foram preservados. Isso verifica reprodução computacional, sem criar novas realizações físicas ou um novo teste cego.

V. Conclusão

Implementou-se uma aplicação de previsão condicionada com auditoria de métricas e referências simples. O limite inicial de treinamento subestimava a LSTM: com maior orçamento, ela empatou na classificação e aproximou-se do ARX na trajetória. Ainda assim, persistir o RMS passado resolve a classificação deste recorte e tem menor erro agregado. Não há base para declarar a arquitetura inferior em geral ou necessária para esse indicador. O resultado é exploratório, sensível ao processamento e sem validação de conforto humano.

Trabalhos futuros devem validar aceleração com sensores independentes, coletar novas realizações e ambos os rótulos dentro de cada classe, além de avaliar assento e passageiros antes de extrapolar conforto. Código, pesos e métricas estão em https://github.com/pedruck/ia-ii-suspensao.

Referências

[1] M. Foo and A. H. Tan, "Benchmark vehicle suspension data based on ISO 8608 road profiles," Zenodo, v3, 2025, doi: 10.5281/zenodo.17242919.

[2] M. Foo and A. H. Tan, "Benchmark vehicle suspension data based on ISO 8608 road profiles," *Control Engineering Practice*, vol. 169, art. 106755, 2026, doi: 10.1016/j.conengprac.2025.106755.

[3] F. A. Vasquez Stuardo, *Optimisation of off-road motorcycle suspensions*, doctoral thesis, University of Southampton, 2020, Appendix A.4. [Online]. Available: https://eprints.soton.ac.uk/448147/

[4] R. Wawryszczuk, E. Kardas-Cinal, J. Lejk and M. Sokolowski, "Methods of Passenger Ride Comfort Evaluation—Tests for Metro Cars," *Sensors*, vol. 23, no. 12, art. 5741, 2023, doi: 10.3390/s23125741.