Previsão Temporal de Suspensão Experimental e Estimativa de um Indicador de Conforto com LSTM

Pedro Druck Montalvão Reis
Disciplina: Inteligência Artificial II

***Abstract*—Este trabalho aplica uma rede LSTM à previsão da resposta de uma suspensão experimental, condicionada ao conhecimento do perfil futuro de pista. Um benchmark público fornece elevações de pista e deslocamentos de carroceria e pneu nas classes de rugosidade A–E. A rede prevê trajetórias de cinco segundos e um indicador agregado de aceleração ponderada, convertido em decisão binária aproximada de conforto vibracional. Avaliam-se um treinamento especializado em C e outro global em A–E, com três sementes e realizações reservadas. A cabeça agregada global atingiu acurácia de 94,4% e macro-F1 de 0,941. Entretanto, a referência linear ARX apresentou menor erro de deslocamento. Os rótulos dependem do processamento da aceleração derivada e as repetições são correlacionadas. Os resultados representam concordância com um indicador de bancada, não validação de conforto de passageiros.**

***Index Terms*—suspensão, LSTM, séries temporais, previsão condicionada, conforto vibracional.**

I. Introdução

Antecipar a resposta da suspensão à irregularidade da pista pode apoiar a análise de condições de rodagem. O problema envolve memória dinâmica: um mesmo deslocamento imposto pode gerar respostas distintas conforme o estado anterior. Neste projeto, aplica-se uma LSTM como técnica conhecida de aprendizado sequencial, sem reivindicar uma arquitetura inédita. O trabalho se enquadra no tema II da disciplina, aplicação de algoritmos à solução de um problema.

A pergunta investigada é se uma previsão condicionada à pista futura pode antecipar um indicador de desconforto em uma realização diferente da usada no ajuste. O conhecimento da excitação futura é uma hipótese explícita: o experimento prevê a resposta a uma pista especificada, não uma pista aleatória desconhecida. As contribuições práticas são o treinamento selecionável por classe de pista, a separação dos trechos repetidos e a avaliação conjunta de trajetórias e decisão agregada.

II. Dados e Formulação

O benchmark de Foo e Tan reúne perfis multissenoidais associados às classes ISO 8608 A–E, aplicados à bancada Quanser, com deslocamentos medidos da carroceria e do pneu [1], [2]. A representação aproximada tem duas coordenadas livres: carroceria z_s e roda z_u, sob elevação prescrita z_r. A deformação relativa da suspensão é $z_s - z_u$.

Cada entrada contém 100.000 amostras a 1.000 Hz, repetidas quatro vezes na aquisição das saídas. Descartou-se o primeiro período de 100 s. O teste usa as realizações com supressão de harmônicos, também geradas com outras fases; portanto, há mudança simultânea da realização e da estrutura harmônica. Não há relatos de passageiros nem representação completa de um veículo [2].

Deformação, frequência de excitação, frequência dominante e frequência natural são grandezas distintas. A condição de frequência dominante até 2 Hz é uma meta adicional do projeto, não uma garantia de conforto. O indicador principal é uma aproximação espectral do RMS da aceleração vertical ponderada:

$$a_w = \left[\sum_{f_k \in [0.5,80]} G_{aa}(f_k) |W_k(f_k)|^2 \Delta f \right]^{1/2}, \qquad (1)$$

com periodograma Hann e ponderação vertical W_k. Os parâmetros das funções de transferência foram conferidos no apêndice A.4 de referência técnica [3]. Testes com ganhos tabulados em 3,15, 12,5 e 50 Hz e uma senoide reproduziram as referências com tolerância de 2%.

Define-se desconforto estimado quando $a_w \geq 0{,}315$ m/s^2, simplificando uma referência indicativa [4]. Essa regra não é limite universal ou certificação ISO. A frequência dominante da carroceria é obtida separadamente na banda 0,5–15 Hz. A resolução básica em cinco segundos é aproximadamente 0,2 Hz.

III. Metodologia

A. Processamento e separação

Os offsets foram estimados nos cinco segundos iniciais de calibração de cada aquisição, anteriores à avaliação. A aceleração é a segunda diferença regressiva do deslocamento, suavizada por filtro causal de quarta ordem a 80 Hz. Um filtro antialias causal comum de oitava ordem a 100 Hz antecede a redução para 250 Hz. Atrasos e atenuações tornam o alvo uma aceleração processada, não uma medição independente.

Checksum, dimensões, valores finitos e pareamento foram conferidos. A sensibilidade ao processamento foi relevante: em C, o indicador principal de desenvolvimento variou de 0,463 a 0,606 m/s^2, enquanto uma suavização alternativa a 40 Hz resultou em 0,239–0,310 m/s^2, mudando o rótulo. Essa alternativa foi diagnóstico; o alvo principal permaneceu fixado.

Cada exemplo tem cinco segundos de histórico e cinco futuros. No treino, usam-se períodos 2 e 3 sem supressão, com histórico e alvo integralmente entre as fases locais 5–60 s. A validação usa fases 70–100 s dos períodos úteis. Todas as repetições da mesma fase ficam no mesmo grupo temporal. O

TABLE I
JANELAS POR MODALIDADE E CONJUNTO.

Treino	Treinamento	Validação	Teste
Somente C	92	15	54
A–E	460	75	270

teste usa apenas as realizações com supressão, períodos 2–4. Normalizadores são ajustados exclusivamente no treino.

O avanço é de um segundo no treino e cinco na validação e teste. Os testes contêm três repetições da realização por classe, não três novos perfis independentes. A e B apresentam apenas o rótulo de conforto; C–E, apenas desconforto no recorte principal. Essa associação limita a interpretação da classificação.

B. Rede, treinamento e referências

Um encoder LSTM recebe o histórico de z_r, z_s, z_u. Um decoder LSTM recebe a pista futura e o estado do encoder, sem saídas futuras reais. Ambos têm uma camada e 64 unidades. Uma projeção linear produz trajetórias de z_s, z_u e aceleração; outra cabeça linear, aplicada à média temporal dos estados do decoder, estima $\log a_w$. Há 35.076 parâmetros.

A cabeça agregada foi adicionada após um piloto de desenvolvimento: a aceleração prevista pontualmente gerou RMS médio de 0,00162 m/s^2, contra 0,5063 m/s^2 na validação. A alteração antecedeu a abertura do teste. A perda é

$$\mathcal{L} = \mathrm{MSE}(\hat{\boldsymbol{y}}_{norm}, \boldsymbol{y}_{norm}) + 0.2\,\mathrm{MSE}(\widehat{\log a_w}, \log a_w). \quad (2)$$

Utilizou-se Adam, taxa 10^{-3}, lote 16, limite da norma do gradiente igual a 1, até 30 épocas e paciência de cinco. Restaurou-se o checkpoint de menor perda de validação nas sementes 42, 43 e 44. O global tem cinco vezes mais janelas que o especializado, mantendo a arquitetura. As execuções usaram T4 via Colab CLI, PyTorch 2.11.0, NumPy 2.4.6 e SciPy 1.16.3. Os seis checkpoints foram recarregados e seus hashes congelados antes do teste.

As referências são persistência da última saída e ARX multivariado com 20 atrasos dos três sinais físicos, entrada de pista atual e regularização ridge 0,1. A previsão ARX é recursiva, sem realimentação futura real. Seus indicadores vêm das trajetórias; a LSTM é avaliada por trajetória e cabeça agregada.

Avaliam-se erros de deslocamento, aceleração, indicador, frequência, pico e curso relativo, incluindo RMSE acumulado até 0,1, 0,5, 1 e 5 s. Para a classificação, usam-se acurácia, macro-F1, acurácia balanceada e recall de desconforto. Métricas de discriminação são omitidas quando só há uma classe verdadeira. Não se calculam intervalos de confiança que suponham independência das janelas correlacionadas.

IV. RESULTADOS E DISCUSSÃO

No global, a LSTM obteve acurácia 0,9444, macro-F1 0,9406 e acurácia balanceada 0,9306 nas três sementes (Tabela II). A matriz de confusão foi idêntica: 93 confortos corretos, 15 falsos alertas de desconforto, 162 desconfortos

TABLE II
TESTE RESERVADO: MÉDIAS DAS TRÊS SEMENTES PARA LSTM.

Treino	Método	RMSE^a	MAE^b	Acc.	F1
C	Persist.	1,006	0,489	0,000	–
C	ARX	0,185	0,024	1,000	–
C	LSTM	0,254	0,047	1,000	–
A–E	Persist.	2,214	0,654	0,400	0,286
A–E	ARX	0,488	0,285	0,800	0,800
A–E	LSTM	0,669	0,121	0,944	0,941

^{a}RMSE da carroceria em mm. ^{b}MAE de a_w em m/s^2; para LSTM, cabeça agregada. Acc.: acurácia; F1: macro-F1.

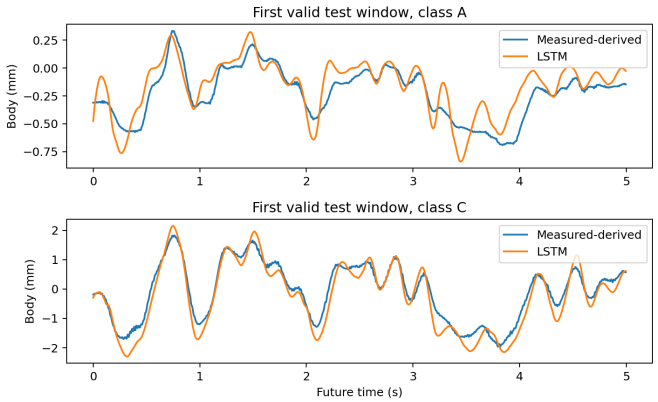


Fig. 1. Primeira janela válida do teste em A e C, modelo global, semente 42. A seleção segue a ordem temporal, não o menor erro. Os deslocamentos medidos são processados.

detectados e nenhum falso conforto. Predizer sempre desconforto, a classe majoritária do treino global, atingiria 60% de acurácia nesse teste.

O MAE do indicador global foi $0{,}121 \pm 0{,}009$ m/s^2 e o RMSE de carroceria $0{,}669 \pm 0{,}034$ mm, com desvio entre sementes. O ARX teve melhor trajetória, com RMSE de 0,488 mm. Os resultados não sustentam superioridade geral da LSTM: há diferenças entre previsão temporal e decisão agregada.

A Fig. 1 ilustra tendências acompanhadas e variações não reproduzidas. Calcular conforto diretamente da aceleração temporal da LSTM global produziu acurácia entre 45,6% e 57,8%, inferior à cabeça agregada. Logo, boa classificação não valida toda a trajetória de aceleração nem a consistência física entre as saídas.

Em C, sempre indicar desconforto permite 100% de acerto, sem demonstrar discriminação binária. A LSTM especializada obteve RMSE de 0,254 mm, ante 0,289 mm do global nesse mesmo teste C. A diversidade não melhorou automaticamente essa classe, e a diferença na quantidade de treino impede isolar seu efeito.

A separação dos rótulos por classe sugere um fator de confusão: reconhecer amplitudes associadas à rugosidade pode explicar parte do desempenho, sem aprender transições de conforto dentro de cada classe. A ausência de falsos confortos nesse teste correlacionado não deve ser generalizada. Na

demonstração salva, 0,6 Hz de frequência prevista coexistiu com RMS aprendido próximo de 0,750 m/s^2, ilustrando que até 2 Hz não substitui um indicador de intensidade.

As principais limitações são a sensibilidade da aceleração derivada ao filtro e ao ruído, a quantidade limitada de realizações, a correlação entre repetições, a hipótese de pista futura conhecida e a ausência de assento e passageiros. Não se variaram parâmetros mecânicos da suspensão. A classificação é concordância com um alvo numérico de bancada.

V. Conclusão

Implementou-se um fluxo reproduzível de previsão condicionada, treinamento por uma ou cinco classes e decisão aproximada de conforto. A cabeça agregada LSTM melhorou a classificação global frente às referências avaliadas; o ARX apresentou menor erro temporal. Os achados justificam separar qualidade da trajetória e do indicador.

Trabalhos futuros devem validar aceleração com sensores independentes, coletar novas realizações e ambos os rótulos dentro de cada classe, além de avaliar assento e passageiros antes de extrapolar conforto. Código, pesos e métricas estão em https://github.com/pedruck/ia-ii-suspensao.

Referências

[1] M. Foo and A. H. Tan, "Benchmark vehicle suspension data based on ISO 8608 road profiles," Zenodo, v3, 2025, doi: 10.5281/zenodo.17242919.

[2] M. Foo and A. H. Tan, "Benchmark vehicle suspension data based on ISO 8608 road profiles," *Control Engineering Practice*, vol. 169, art. 106755, 2026, doi: 10.1016/j.conengprac.2025.106755.

[3] F. A. Vasquez Stuardo, *Optimisation of off-road motorcycle suspensions*, doctoral thesis, University of Southampton, 2020, Appendix A.4. [Online]. Available: https://eprints.soton.ac.uk/448147/

[4] R. Wawryszczuk, E. Kardas-Cinal, J. Lejk and M. Sokolowski, "Methods of Passenger Ride Comfort Evaluation—Tests for Metro Cars," *Sensors*, vol. 23, no. 12, art. 5741, 2023, doi: 10.3390/s23125741.