Previsão Temporal de Suspensão Experimental e Estimativa de um Indicador de Conforto com LSTM

Pedro Druck Montalvão Reis
Disciplina: Inteligência Artificial II

***Abstract*—Aplica-se uma LSTM à previsão de cinco segundos da resposta de uma suspensão experimental, condicionada ao conhecimento da pista futura. Um benchmark público fornece pistas A–E e deslocamentos medidos. Além das trajetórias, estima-se um indicador agregado de aceleração ponderada, convertido em rótulo aproximado de conforto. O modelo global alcançou 94,4% de acurácia. Uma análise exploratória posterior, entretanto, obteve 96,7% com apenas a amplitude da pista e 100% com oito características simples, sem demonstrar vantagem da rede na classificação. O ARX também apresentou menor erro de deslocamento. Uma comparação padronizada de filtros mudou 53 de 54 rótulos da classe C no teste, evidenciando sensibilidade física do alvo. As 270 janelas globais representam 90 fases repetidas três vezes. Os resultados caracterizam um indicador processado de bancada, não conforto validado em passageiros.**

***Index Terms*—suspensão, LSTM, séries temporais, previsão condicionada, conforto vibracional.**

I. Introdução

Antecipar a resposta da suspensão à irregularidade da pista pode apoiar a análise de condições de rodagem. O problema envolve memória dinâmica: um mesmo deslocamento imposto pode gerar respostas distintas conforme o estado anterior. Neste projeto, aplica-se uma LSTM como técnica conhecida de aprendizado sequencial, sem reivindicar uma arquitetura inédita. O trabalho se enquadra no tema II da disciplina, aplicação de algoritmos à solução de um problema.

A pergunta investigada é se uma previsão condicionada à pista futura pode antecipar um indicador de desconforto em uma realização diferente da usada no ajuste. O conhecimento da excitação futura é uma hipótese explícita: o experimento prevê a resposta a uma pista especificada, não uma pista aleatória desconhecida. As contribuições práticas são o treinamento selecionável por classe de pista, a separação dos trechos repetidos e a avaliação conjunta de trajetórias e decisão agregada.

II. Dados e Formulação

O benchmark de Foo e Tan reúne perfis multissenoidais associados às classes ISO 8608 A–E, aplicados à bancada Quanser, com deslocamentos medidos da carroceria e do pneu [1], [2]. A representação aproximada tem duas coordenadas livres: carroceria z_s e roda z_u, sob elevação prescrita z_r. A deformação relativa da suspensão é $z_s - z_u$.

Cada entrada contém 100.000 amostras a 1.000 Hz, repetidas quatro vezes na aquisição das saídas. Descartou-se o primeiro período de 100 s. O teste usa as realizações com supressão de harmônicos, também geradas com outras fases; portanto, há mudança simultânea da realização e da estrutura harmônica. Não há relatos de passageiros nem representação completa de um veículo [2].

Deformação, frequência de excitação, frequência dominante e frequência natural são grandezas distintas. A condição de frequência dominante até 2 Hz é uma meta adicional do projeto, não uma garantia de conforto. O indicador principal é uma aproximação espectral do RMS da aceleração vertical ponderada:

$$a_w = \left[\sum_{f_k \in [0.5,80]} G_{aa}(f_k) |W_k(f_k)|^2 \Delta f \right]^{1/2}, \qquad (1)$$

com periodograma Hann e ponderação vertical W_k. Os parâmetros das funções de transferência foram conferidos no apêndice A.4 de referência técnica [3]. Testes com ganhos tabulados em 3,15, 12,5 e 50 Hz e uma senoide reproduziram as referências com tolerância de 2%.

Define-se desconforto estimado quando $a_w \geq 0{,}315$ m/s^2, simplificando uma referência indicativa [4]. Essa regra não é limite universal ou certificação ISO. A frequência dominante da carroceria é obtida separadamente na banda 0,5–15 Hz. A resolução básica em cinco segundos é aproximadamente 0,2 Hz.

III. Metodologia

A. Processamento e separação

Os offsets foram estimados nos cinco segundos iniciais de calibração de cada aquisição, anteriores à avaliação. A aceleração é a segunda diferença regressiva do deslocamento, suavizada por filtro causal de quarta ordem a 80 Hz. Um filtro antialias causal comum de oitava ordem a 100 Hz antecede a redução para 250 Hz. Atrasos e atenuações tornam o alvo uma aceleração processada, não uma medição independente.

Checksum, dimensões, valores finitos e pareamento foram conferidos. A análise adicional padronizou os cortes de 40, 60 e 80 Hz, mantendo idênticos centralização, antialias, amostragem e janelas. Testou-se também uma senoide de amplitude conhecida com ruído sintético em níveis definidos. Esses diagnósticos não identificam o ruído real da bancada. O alvo de 80 Hz foi mantido, sem selecionar a banda pela acurácia.

Cada exemplo tem cinco segundos de histórico e cinco futuros. No treino, usam-se períodos 2 e 3 sem supressão, com histórico e alvo integralmente entre as fases locais 5–60 s. A validação usa fases 70–100 s dos períodos úteis. Todas as

TABLE I
JANELAS POR MODALIDADE E CONJUNTO.

Treino	Treinamento	Validação	Teste
Somente C	92	15	54
A–E	460	75	270

repetições da mesma fase ficam no mesmo grupo temporal. O teste usa apenas as realizações com supressão, períodos 2–4. Normalizadores são ajustados exclusivamente no treino.

O avanço é de um segundo no treino e cinco na validação e teste. Os testes contêm três repetições da realização por classe, não três novos perfis independentes. A e B apresentam apenas o rótulo de conforto; C–E, apenas desconforto no recorte principal. Essa associação limita a interpretação da classificação.

B. Rede, treinamento e referências

Um encoder LSTM recebe o histórico de z_r, z_s, z_u. Um decoder LSTM recebe a pista futura e o estado do encoder, sem saídas futuras reais. Ambos têm uma camada e 64 unidades. Uma projeção linear produz trajetórias de z_s, z_u e aceleração; outra cabeça linear, aplicada à média temporal dos estados do decoder, estima $\log a_w$. Há 35.076 parâmetros.

A cabeça agregada foi adicionada após um piloto de desenvolvimento: a aceleração prevista pontualmente gerou RMS médio de 0,00162 m/s^2, contra 0,5063 m/s^2 na validação. A alteração antecedeu a abertura do teste. A perda é

$$\mathcal{L} = \mathrm{MSE}(\hat{\boldsymbol{y}}_{norm}, \boldsymbol{y}_{norm}) + 0.2\,\mathrm{MSE}(\widehat{\log a_w}, \log a_w). \quad (2)$$

Utilizou-se Adam, taxa 10^{-3}, lote 16, limite da norma do gradiente igual a 1, até 30 épocas e paciência de cinco. Restaurou-se o checkpoint de menor perda de validação nas sementes 42, 43 e 44. O global tem cinco vezes mais janelas que o especializado, mantendo a arquitetura. As execuções usaram T4 via Colab CLI, PyTorch 2.11.0, NumPy 2.4.6 e SciPy 1.16.3. Os seis checkpoints foram recarregados e seus hashes congelados antes do teste.

As referências são persistência da última saída e ARX multivariado com 20 atrasos dos três sinais físicos, entrada de pista atual e regularização ridge 0,1. A previsão ARX é recursiva, sem realimentação futura real. Seus indicadores vêm das trajetórias; a LSTM é avaliada por trajetória e cabeça agregada.

Em uma segunda análise exploratória, acrescentaram-se três referências diretas para $\log a_w$: média constante do treino; regressão com log-desvio padrão da pista futura; e ridge com oito características logarítmicas. Estas incluem desvios padrão da pista futura, da carroceria, pneu e pista históricos, RMS das primeiras e segundas diferenças da pista futura e desvios padrão do curso relativo e da diferença pneu–pista no histórico. A classe ISO e as respostas futuras não são entradas. A padronização usa apenas o treino. A regularização é escolhida em $\{0{,}001; 0{,}01; 0{,}1; 1; 10; 100\}$ pela perda de validação em log-RMS. Para A–E, selecionou-se 0,001 nas duas regressões.

TABLE II
TRAJETÓRIA: RMSE DA CARROCERIA EM MM.

Treino	Persistência	ARX	LSTM
C	1,006	0,185	0,254
A–E	2,214	0,488	0,669

TABLE III
INDICADOR DIRETO GLOBAL: ANÁLISE EXPLORATÓRIA ADICIONAL.

Método	MAE[a]	Acc. (%)	Macro-F1
Constante	0,453	60,0	0,375
Amplitude da pista	0,134	96,7	0,966
Ridge, 8 características	0,062	100,0	1,000
LSTM, cabeça agregada	0,121	94,4	0,941

[a] Erro de a_w em m/s^2. LSTM: média das três sementes. Os resultados são concordância com rótulos processados.

Essas referências são comparadas à cabeça agregada; ARX e LSTM são comparados separadamente como preditores de trajetória. O teste original já havia sido consultado antes dessa ampliação, que não constitui um novo teste cego. Não houve retreino da LSTM orientado por seus resultados.

Avaliam-se erros de deslocamento, aceleração, indicador, frequência, pico e curso relativo, incluindo RMSE acumulado até 0,1, 0,5, 1 e 5 s. Para a classificação, usam-se acurácia, macro-F1, acurácia balanceada e recall de desconforto. Métricas de discriminação são omitidas quando só há uma classe verdadeira. Não se calculam intervalos de confiança que suponham independência das janelas correlacionadas.

IV. RESULTADOS E DISCUSSÃO

No global, a LSTM obteve acurácia 0,9444, macro-F1 0,9406 e acurácia balanceada 0,9306 nas três sementes (Tabela III). A matriz de confusão foi idêntica: 93 confortos corretos, 15 falsos alertas de desconforto, 162 desconfortos detectados e nenhum falso conforto. Predizer sempre desconforto, a classe majoritária do treino global, atingiria 60% de acurácia nesse teste.

A Tabela III muda a interpretação da classificação: a amplitude da pista, isoladamente, alcançou 96,7%, e a ridge de oito características, 100%. O MAE desta última foi 0,062 m/s^2, inferior a 0,121 da LSTM. Como as classes de pista praticamente separam os rótulos, a rede pode reconhecer intensidade sem aprender transições de conforto dentro de cada classe. O desempenho agregado não estabelece vantagem da LSTM frente às referências diretas. Os 100% também não validam conforto humano ou generalização para novas configurações.

O MAE do indicador global foi $0{,}121 \pm 0{,}009$ m/s^2 e o RMSE de carroceria $0{,}669 \pm 0{,}034$ mm, com desvio entre sementes. O ARX teve melhor trajetória, com RMSE de 0,488 mm. Os resultados não sustentam superioridade geral da LSTM: há diferenças entre previsão temporal e decisão agregada.

A Fig. 1 ilustra tendências acompanhadas e variações não reproduzidas. Calcular conforto diretamente da aceleração

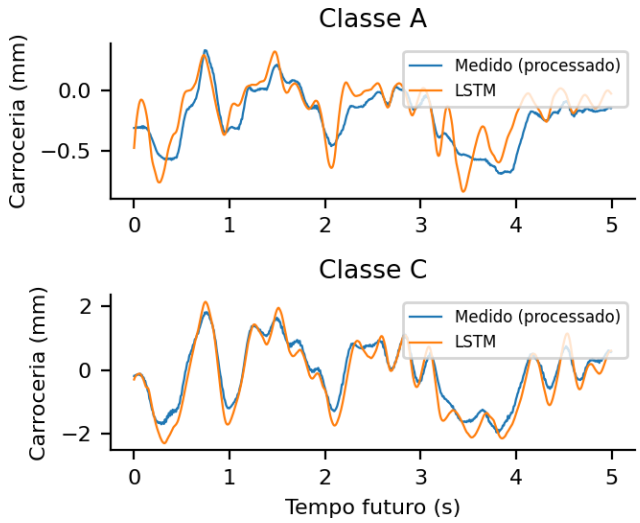


Fig. 1. Primeira janela válida do teste em A e C, modelo global, semente 42. A seleção segue a ordem temporal, não o menor erro. Os deslocamentos medidos são processados.

temporal da LSTM global produziu acurácia entre 45,6% e 57,8%, inferior à cabeça agregada. Logo, boa classificação não valida toda a trajetória de aceleração nem a consistência física entre as saídas.

Em C, sempre indicar desconforto permite 100% de acerto, sem demonstrar discriminação binária. A LSTM especializada obteve RMSE de 0,254 mm, ante 0,289 mm do global nesse mesmo teste C. A diversidade não melhorou automaticamente essa classe, e a diferença na quantidade de treino impede isolar seu efeito.

A separação dos rótulos por classe sugere um fator de confusão: reconhecer amplitudes associadas à rugosidade pode explicar parte do desempenho, sem aprender transições de conforto dentro de cada classe. A ausência de falsos confortos nesse teste correlacionado não deve ser generalizada. Na demonstração salva, 0,6 Hz de frequência prevista coexistiu com RMS aprendido próximo de 0,750 m/s^2, ilustrando que até 2 Hz não substitui um indicador de intensidade.

Na análise padronizada de C no teste, os cortes de 40, 60 e 80 Hz produziram intervalos de a_w de 0,245–0,333, 0,394–0,510 e 0,428–0,549 m/s^2, respectivamente. Reduzir de 80 para 40 Hz alterou 53 dos 54 rótulos. No corte principal, 93,2% da energia ponderada de C estava entre 20 e 80 Hz. Isso não demonstra que tal energia seja ruído, mas impede assumir a validade física dos rótulos sem uma medição independente.

As curvas de treino/validação, dispersões do indicador e erros por classe e horizonte foram exportados. A análise por passagem e após média das fases repetidas evita interpretar as 270 janelas globais como 270 ensaios independentes: há 90 fases distintas, de uma realização por classe. Não são apresentadas significâncias estatísticas baseadas em independência inexistente.

As principais limitações são a sensibilidade da aceleração derivada ao filtro e ao ruído, a quantidade limitada de realizações, a correlação entre repetições, a hipótese de pista futura conhecida e a ausência de assento e passageiros. Não se variaram parâmetros mecânicos da suspensão. A classificação é concordância com um alvo numérico de bancada.

A sequência completa foi reexecutada em outro runtime T4, incluindo obtenção dos dados, processamento, ajuste das referências, seis treinamentos, congelamento e avaliação. Vinte e três testes passaram. A conferência das métricas de RMSE da carroceria, MAE do indicador e acurácia, por execução e classe, não encontrou diferenças em relação aos registros originais. Pesos, logs, hashes e uma cópia do código executado foram preservados. Isso verifica reprodução computacional, sem criar novas realizações físicas ou um novo teste cego.

V. Conclusão

Implementou-se uma aplicação reproduzível de previsão condicionada com treinamento por uma ou cinco classes. A avaliação adicional não demonstrou vantagem da LSTM: ARX teve menor erro temporal, e uma regressão simples superou a cabeça de indicador. A análise identifica limites do alvo e mostra a importância de referências que resolvam a mesma tarefa. O resultado é uma aplicação exploratória com comparação crítica, sem validação de conforto em passageiros.

Trabalhos futuros devem validar aceleração com sensores independentes, coletar novas realizações e ambos os rótulos dentro de cada classe, além de avaliar assento e passageiros antes de extrapolar conforto. Código, pesos e métricas estão em https://github.com/pedruck/ia-ii-suspensao.

Referências

[1] M. Foo and A. H. Tan, “Benchmark vehicle suspension data based on ISO 8608 road profiles,” Zenodo, v3, 2025, doi: 10.5281/zenodo.17242919.

[2] M. Foo and A. H. Tan, “Benchmark vehicle suspension data based on ISO 8608 road profiles,” *Control Engineering Practice*, vol. 169, art. 106755, 2026, doi: 10.1016/j.conengprac.2025.106755.

[3] F. A. Vasquez Stuardo, *Optimisation of off-road motorcycle suspensions*, doctoral thesis, University of Southampton, 2020, Appendix A.4. [Online]. Available: https://eprints.soton.ac.uk/448147/

[4] R. Wawryszczuk, E. Kardas-Cinal, J. Lejk and M. Sokolowski, “Methods of Passenger Ride Comfort Evaluation—Tests for Metro Cars,” *Sensors*, vol. 23, no. 12, art. 5741, 2023, doi: 10.3390/s23125741.